

技术文档

1. 摘要

本技术文档详细阐述多模态客服智能体的整体架构设计、核心技术实现方案及创新点，针对赛题要求的“多模态感知-精准理解-知识增强”全链路需求，构建具备多模态对话理解、RAG 知识增强、多轮对话与幻觉抑制能力的智能体，为产业级客服系统提供技术支撑。本智能体基于 FastAPI 封装标准 RESTful API 接口，整合文本与视觉模型，依托 RAG 知识库实现精准问答，通过模板匹配与思维链拆解，确保回答的准确性、连贯性与合规性。

2. 整体架构设计

本多模态客服智能体采用分层模块化架构，自上而下分为接口层、核心业务层、知识库层、模型层四层，各层独立解耦，便于部署、调试与优化，整体架构如下：

(此处可插入架构图，AI 生成提示：绘制多模态客服智能体分层架构图，包含接口层、核心业务层、知识库层、模型层，标注各层核心模块及数据流向，简洁清晰，适配竞赛文档)

各层核心功能说明：

- 接口层：**基于 FastAPI 构建，提供标准 RESTful API 接口 (/chat 核心端点)，支持接收 JSON 格式文本和 Base64 格式图片，实现用户请求的接收与响应，同时包含认证、健康检查、统计等辅助接口。
- 核心业务层：**整合多模态理解、RAG 检索、多轮对话管理、幻觉抑制四大核心模块，是智能体的核心逻辑载体，负责处理用户请求、调用底层模型与知识库，生成合规回答。
- 知识库层：**构建多模态使用手册知识库，支持 PDF、Word、TXT 等多种格式文档的文本与图片提取，通过 FAISS 向量数据库实现知识的高效存储与精准检索。
- 模型层：**集成文本模型 (DeepSeek-V4-Flash) 与视觉模型 (Qwen/Qwen3-VL-32B-Instruct)，分别负责文本理解与图片内容解析，为核心业务层提供技术支撑。

3. 核心技术实现方案

3.1 多模态理解模块

本模块负责精准识别用户意图，支持文本+图片双模态输入，适配赛题中“顾客的问题和图片，准确全面地识别当前用户意图”的要求，具体实现如下：

- 文本理解：采用关键词匹配与大模型结合的方式，先通过预设的关键词规则（如物流、保修、支付等分类）快速匹配客服模板，提升简单问题的响应速度；对于复杂问题，调用 DeepSeek-V4-Flash 文本模型，结合上下文与知识库内容，精准解析用户意图。
- 图片理解：接收用户上传的 Base64 格式图片，调用 Qwen3-VL-32B-Instruct 视觉模型，对图片内容进行详细描述，将图片信息转化为文本，融入后续问答逻辑，实现多模态信息的协同理解。
- 格式适配：支持图片 Base64 编码解析，自动处理图片大小限制（最大 5MB），确保多模态输入的兼容性与稳定性。

3.2 RAG 库设计与实现

按照赛题要求，构建多模态使用手册知识库（使用手册+手册插图），实现用户问题与知识库内容的精准匹配，具体实现如下：

- 文档解析：支持 PDF、Word、TXT 三种格式的知识库文档解析，从 PDF 中提取文本与图片，从 Word 和 TXT 中提取文本，自动生成文本片段与图片元数据，确保知识库内容的完整性。
- 文本拆分：采用 RecursiveCharacterTextSplitter 文本拆分工具，按 256 字符长度拆分文本，重叠度 30 字符，避免文本片段过长或过短，提升检索精度。
- 向量数据库构建：基于 BAAI/bge-large-zh-v1.5 嵌入模型，将文本片段转化为向量，通过 FAISS 向量数据库实现高效存储；采用分批处理方式（每批 32 个文本块），避免超出 API 限制，确保向量数据库构建的稳定性。
- 精准检索：针对用户问题，通过向量相似度检索，获取 Top3 相关文本片段，同时关联对应的图片元数据，返回相关配图 ID，实现“文本+图片”的协同检索，贴合赛题要求。

3.3 多轮对话与幻觉抑制机制

针对赛题“思维链拆解复杂问题、拆分多个问题——作答”“幻觉抑制”的要求，具体实现如下：

- 多轮对话管理：通过会话 ID (session_id) 维护用户对话历史，支持自动生成会话 ID，保留最近 3 轮对话上下文（最多 12 条消息），确保多轮对话的连贯性；区分批量模式与普通模式，批量测试（400 题）时不保存上下文，提升处理效率。
- 复杂问题拆解：通过大模型思维链引导，对用户一次提出的多个问题（如“能否送到乡镇？需要加运费吗？”）进行拆分，逐一匹配知识库内容，分别给出精准回答，确保不遗漏用户需求。
- 幻觉抑制：严格遵循“基于知识库回答”的原则，在系统提示中明确要求只回答知

识库中明确提及的内容，禁止编造信息；通过模板匹配与 RAG 检索双重校验，确保回答的准确性，避免幻觉生成；限制回答长度（100 字以内），进一步降低幻觉概率。

3.4 API 接口封装

按照赛题要求，封装为标准 RESTful API 服务，核心实现如下：

- 核心端点：/chat 端点，支持 POST 请求，接收 question（用户问题）、session_id（会话 ID）、image（图片 Base64 编码）三个参数，返回包含 answer（回答）、session_id、ret（相关图片 ID 列表）的响应数据。
- 认证机制：采用 Bearer Token 认证，确保接口调用的安全性，符合竞赛规范。
- 辅助接口：提供/health 健康检查接口（查看服务状态与知识库加载情况）、/stats 统计接口（查看会话数量、知识库状态等），便于评审调试与验证。
- 超时控制：文本模型请求超时 20 秒，视觉模型请求超时 30 秒，确保服务稳定性，避免长期阻塞。

4. 技术亮点与创新点

4.1 技术亮点

- 多模态协同优化：文本与视觉模型深度结合，图片解析结果融入 RAG 检索与问答逻辑，实现“文本+图片”的精准匹配，贴合赛题多模态需求。
- 高效 RAG 检索：采用分批构建向量数据库、关键词匹配+向量检索双重策略，兼顾检索速度与精度，确保用户问题能快速匹配到相关知识库内容。
- 接口标准化：严格遵循 RESTful API 规范，封装清晰、文档完善，支持多场景调用（普通对话、批量测试），适配竞赛评审的验证需求。
- 高可用性：完善的日志系统、异常处理机制、健康检查接口，确保服务稳定运行，便于部署与调试。

4.2 创新点

- 模板匹配与 RAG 检索融合：简单问题通过模板快速响应，复杂问题通过 RAG 检索精准回答，兼顾响应速度与回答质量，提升用户体验。
- 动态会话管理与批量模式适配：区分普通对话与批量测试模式，批量测试时不保存上下文，提升 400 题测试的处理效率，同时保证普通多轮对话的连贯性。
- 幻觉抑制双重保障：通过系统提示严格约束回答范围，结合 RAG 检索结果校验，有效降低幻觉生成概率，确保回答的准确性与合规性。

5. 核心痛点解决方案

针对赛题提出的“多模态信息理解不准、幻觉回答”等痛点，本智能体给出以下解决方案：

- 多模态理解不准：采用“关键词匹配+大模型解析+图片描述”三重机制，精准识别用户意图；图片解析与文本检索协同，避免单一模态信息的局限性。
- 幻觉回答：严格基于知识库内容回答，通过系统提示约束、RAG 检索校验、回答长度限制，三重保障避免幻觉生成；核心逻辑不依赖模型自主编造，确保回答的客观性。
- 复杂问题处理：通过思维链拆解复杂问题，逐一作答，避免遗漏用户需求；多轮对话上下文管理，确保对话连贯性，提升复杂场景的适配能力。